# Phase 2a 実験ノート

β 条件付き DDPM による 32×32 Polyakov Loop Map の生成

*— 条件付き拡散モデルは格子ゲージ理論の相構造を学習できるか —*

## 0. この文書について

この文書は、2+1 次元 U(1) コンパクト格子ゲージ理論のモンテカルロ (MC) シミュレーションで生成した Polyakov loop map を、拡散確率モデル (DDPM) で再現する実験（Phase 2a）の記録である。目的は「条件付き生成モデルが、結合定数 β に応じた相構造を持つ分布を学べるか」を検証することにある。初学者にも追えるよう、背景知識から順に説明する。

## 1. 背景：格子ゲージ理論と Polyakov Loop

### 1.1 格子ゲージ理論とは

素粒子物理学では、クォーク間の力（強い力）を記述するために「ゲージ理論」という枠組みを使う。しかし解析的に解くのが極めて難しいため、空間を離散的な格子に区切り、計算機上でモンテカルロ・シミュレーションを行う手法が発展した。これが**格子ゲージ理論**である。

本実験では簡略化モデルとして **2+1 次元 U(1) コンパクト格子ゲージ理論** を扱う。「U(1)」は電磁気力に対応する対称群、「2+1 次元」は空間 2 次元 ＋ 時間 1 次元、「コンパクト」は角度変数 $\theta \in [-\pi, \pi]$ でリンク変数を表すことを意味する。QCD の SU(3) に比べて計算が軽く、しかし閉じ込め・非閉じ込め相転移という本質的な物理を持つため、手法検証に適している。

### 1.2 Polyakov Loop：相転移の指標

**Polyakov loop** は格子の時間方向に沿ってリンク変数を一周分かけ合わせた量で、空間の各サイト (x, y) に一つの複素数 $P(x,y) = \exp(i\theta)$ を与える。これを空間全体で平均した $\langle |P| \rangle$ が**秩序パラメータ**となる。

結合定数 β が小さいとき（高温 = 閉じ込め相）、Polyakov loop はランダムに揺らぎ $\langle |P| \rangle \approx 0$ となる。β が大きいとき（低温 = 非閉じ込め相）、Polyakov loop は秩序化し $\langle |P| \rangle \to 1$ に近づく。この間に **相転移** があり、U(1) の場合 $\beta \approx 1.0$〜$2.0$ の領域で急峻な変化が起きる。

### 1.3 なぜ DDPM か

**Denoising Diffusion Probabilistic Model (DDPM)** (Ho et al. 2020) は、画像にガウスノイズを徐々に加え（前向き過程）、それを逆に除去するニューラルネットワークを学習する（逆過程）生成モデルである。GAN と異なりモード崩壊が起きにくく、分布全体をカバーする生成が得意とされる。

格子ゲージ理論のシミュレーションは計算コストが高い。もし DDPM がある β での配位分布を正しく学習できれば、訓練後は MC を回さずに新しい配位を高速生成できる可能性がある。さらに β 条件付けに成功すれば、訓練に使っていない β での内挿生成（emulator）への道が開ける。

# 2. 手法

## 2.1 DDPM の仕組み（直感的説明）

DDPM の学習は次のように進む。まず訓練データ $x_0$ に、ランダムに選んだタイムステップ t に応じた強さのガウスノイズ ε を加え、ノイズ付きデータ $x_t$ を作る。次にニューラルネットワーク（U-Net）に $x_t$ と t を入力し、加えたノイズ ε を予測させる。予測 $\hat{\varepsilon}$ と真のノイズ ε の MSE がロスとなる。

生成時は、純粋なガウスノイズ x_T から出発し、学習済みネットワークの予測を使って少しずつノイズを除去していく。T=1000 ステップかけて $x_0$ に到達する。

## 2.2 β 条件付けの方法

結合定数 β をモデルに伝えるため、タイムステップ t の sinusoidal embedding と同じ空間に β を射影し、両者を加算して一つの条件ベクトルとする。この条件ベクトルは Adaptive Group Normalization (AdaGN) を通じて U-Net の各 ResBlock に注入される。

具体的には: (1) t → sinusoidal embedding → 2 層 MLP → 256 次元ベクトル、(2) β（[0,1] に正規化） → 2 層 MLP → 256 次元ベクトル、(3) 両者を加算 → SiLU → Linear → 最終条件ベクトル。

加算を選んだ理由は、連結（concatenation）すると条件ベクトルの次元が倍になり下流の全レイヤーに影響するのに対し、加算は「β と t は同じ条件空間に住む」という仮定のもとでシンプルに統合できるためである。

## 2.3 アーキテクチャの設計判断

本実験の設計では 5 つの判断を事前に明示し、それぞれに監査基準を設けた。以下の表にまとめる。

| # | 判断 | 根拠 | 監査結果 |
|---|---|---|---|
| 判断 1 | 入力表現: 2ch (Re, Im) | θ は ±π で不連続。(cos θ, sin θ) は滑らか。 | 各サイト $\lvert Re^2+Im^2-1\rvert$ を測定 → 0.003 で合格 |
| 判断 2 | Cosine ノイズスケジュール | 32×32 の小画像では linear より信号保持が良い (Nichol & Dhariwal 2021)。 | loss curve が安定して収束 → 問題なし |
| 判断 3 | β を time embedding に加算 | β も t も連続スカラー条件。加算で次元を倍にしない。 | held-out β=1.75, 1.85 で滑らかな補間を確認 |
| 判断 4 | Circular padding (PBC 準拠) | 格子場はトーラス上に定義される。境界の不連続を防ぐ。 | 境界アーティファクトなし（目視確認） |
| 判断 5 | 3-level U-Net (64,128,256) | 32×32 に対して十分な表現力。~7.5M params で過学習リスク低。 | 全 β で MC と Δ<0.01 → 表現力は十分 |

*表 1: 設計判断とその監査結果。各判断に対し事前に監査基準を設定し、実験後に検証した。*

## 2.4 U-Net アーキテクチャ

3 レベルの U-Net を採用した。エンコーダは 32×32×64 → 16×16×128 → 8×8×256 と解像度を半分ずつ落としながらチャンネルを増やす。ボトルネック（4×4×256）には Self-Attention を配置し、大域的な Polyakov ドメイン構造の一貫性を保つ。デコーダは対称的に解像度を戻す。パラメータ数は約 7.5M。

全ての畳み込みに `padding_mode='circular'` を使用した（判断 4）。格子場はトーラス上に定義されるため、周期的境界条件 (PBC) を畳み込みレベルで尊重する必要がある。

# 3. 実験設定

## 3.1 データ

Phase 1 で生成した 2+1 次元 U(1) コンパクト格子ゲージ理論の MC データを使用。格子サイズ 32×32、β = {0.5, 1.0, 1.5, 1.7, 1.9, 2.0, 2.5, 4.0, 6.0, 10.0} の各値で数千配位を収集。各配位は Polyakov loop map として 32×32 の複素数場に変換され、Re(P) と Im(P) の 2 チャンネル画像として格納される。

D4（二面体群）対称性によるオンライン augmentation を適用し、データ量を 8 倍に拡張した。D4 は 90°/180°/270° 回転と上下・左右・対角反転の 8 操作からなり、正方格子の物理的対称性と一致する。

## 3.2 ハイパーパラメータ

| パラメータ | 値 |
|---|---|
| 拡散ステップ数 T | 1000 |
| ノイズスケジュール | Cosine (s = 0.008) |
| エポック数 | 200 |
| バッチサイズ | 64 |
| 学習率 | $2 \times 10^{-4}$ (AdamW, weight_decay=$10^{-4}$) |
| LR スケジュール | Cosine annealing with warmup (1000 steps) |
| EMA decay | 0.9999 |
| 入力チャンネル | 2 (Re, Im) |
| U-Net チャンネル | (64, 128, 256) |
| GPU | Kaggle T4 (16 GB VRAM) |

*表 2: 主要ハイパーパラメータ。*

# 4. コードの核心部

以下では、実装の中で物理的・技術的に重要な箇所を抜粋して解説する。

## 4.1 周期的境界条件の畳み込み

格子場は周期的境界条件 (PBC) を持つ。通常の zero-padding では画像端で不連続が生じ、非物理的なアーティファクトが発生する。PyTorch の circular padding モードを使い、これを回避した。

```
def circ_conv(in_ch, out_ch, kernel_size=3, stride=1, bias=True):
    return nn.Conv2d(in_ch, out_ch, kernel_size, stride=stride,
                     padding=kernel_size // 2,
                     padding_mode='circular', bias=bias)
```

kernel_size=3, padding=1 の場合、各辺 1 ピクセルが反対側の辺からコピーされる。32×32 格子では物理的に正しい折り返しとなる。

## 4.2 条件付き embedding の加算

タイムステップ t と結合定数 β を同一の 256 次元空間に埋め込み、加算する。

```
# time_emb: sinusoidal(t) → MLP → 256-dim
# beta_emb: MLP(β_normed) → 256-dim
combined = self.combine(time_emb + beta_emb)
```

この combined ベクトルが Adaptive Group Normalization (AdaGN) を介して U-Net の全 ResBlock に注入される。AdaGN は Group Normalization の出力に対して、条件ベクトルから算出した scale と shift を適用する: h' = (1 + scale) × GN(h) + shift。

## 4.3 ボトルネック Self-Attention

4×4 ボトルネック（16 トークン）にのみ Multi-Head Self-Attention を配置した。Polyakov loop は大域的な秩序パラメータであり、CNN の局所的な受容野だけでは空間全体にわたる位相整合性を保証できない。4×4 解像度での attention は計算量 $O(16^2) = O(256)$ と軽量でありながら、大域的な情報統合を実現する。

## 4.4 前向き過程と学習ロス

DDPM の学習は単純な MSE ロスに帰着する。

```
# x₀: 元データ, t: ランダムなタイムステップ, ε: ガウスノイズ
xₜ = √ᾱₜ × x₀ + √(1−ᾱₜ) × ε   # 前向き過程
ε̂ = model(xₜ, t, β)            # ネットワーク予測
loss = MSE(ε̂, ε)                # 学習ロス
```

$\bar{\alpha}_t$ は cosine schedule で定義される累積ノイズ係数。t が大きいほど $\bar{\alpha}_t \to 0$ となり、$x_t$ は純粋なノイズに近づく。

# 5. 結果

## 5.1 学習曲線

図 1（左）に MSE loss の推移を示す。epoch 25 前後で急速に収束し、以降 200 epoch まで安定している。過学習の兆候（loss の再上昇）は見られない。cosine LR schedule による滑らかな減衰と、EMA による平滑化が寄与していると考えられる。

## 5.2 生成結果 vs MC 参照値

各 β について EMA モデルで 100 枚のサンプルを生成し、空間平均 Polyakov loop ⟨ |P|⟩ を算出した。MC シミュレーションの参照値との比較を表 3 に示す。

| β | 区分 | DDPM ⟨ \|P\|⟩ | σ | MC ⟨ \|P\|⟩ | Δ | 判定 |
|---|---|---|---|---|---|---|
| 0.50 | TRAIN | 0.027 | 0.013 | 0.029 ± 0.002 | 0.002 | ✓ |
| 1.00 | TRAIN | 0.030 | 0.016 | 0.032 ± 0.002 | 0.002 | ✓ |
| 1.50 | TRAIN | 0.067 | 0.039 | 0.063 ± 0.002 | 0.004 | ✓ |
| 1.70 | TRAIN | 0.108 | 0.051 | 0.114 ± 0.005 | 0.006 | ✓ |
| **1.75** | **HELD-OUT** | **0.140** | **0.072** | **—** | **—** | |
| **1.85** | **HELD-OUT** | **0.216** | **0.089** | **—** | **—** | |
| 1.90 | TRAIN | 0.265 | 0.108 | 0.262 ± 0.020 | 0.003 | ✓ |
| 2.00 | TRAIN | 0.382 | 0.098 | 0.378 ± 0.025 | 0.004 | ✓ |
| 2.50 | TRAIN | 0.567 | 0.051 | 0.562 ± 0.004 | 0.005 | ✓ |
| **3.00** | **HELD-OUT** | **0.626** | **0.046** | **—** | **—** | |
| 4.00 | TRAIN | 0.713 | 0.040 | 0.715 ± 0.004 | 0.002 | ✓ |
| 6.00 | TRAIN | 0.804 | 0.027 | 0.805 ± 0.003 | 0.001 | ✓ |
| **8.00** | **HELD-OUT** | **0.851** | **0.021** | **—** | **—** | |
| 10.00 | TRAIN | 0.884 | 0.014 | 0.883 ± 0.002 | 0.001 | ✓ |

*表 3: 生成サンプルの ⟨ |P|⟩ と MC 参照値の比較。σ は 100 サンプルの標準偏差。Δ = |DDPM − MC|。HELD-OUT（青太字）は訓練に使用していない β。判定は Δ < 3σ_MC + 0.05 を基準とした。*

訓練 β 全 10 点で最大偏差は Δ = 0.006 (β = 1.70) であり、MC の統計誤差と同程度である。特に相転移領域 β ≈ 1.7〜2.0 で ⟨ |P|⟩ が 0.1 → 0.38 と急峻に変化する部分を正確に追従している点が重要で、β 条件付けが単に全 β の平均を出力しているのではなく、β ごとに異なる分布を学習していることを示唆する。

held-out β（1.75, 1.85, 3.0, 8.0）についても、隣接する訓練点の間に滑らかに位置しており、β embedding の連続性を活かした補間が機能していることが分かる。

## 5.3 Unit Circle 拘束の検証

Polyakov loop は P = exp(iθ) という単位円上の値であるため、$Re(P)^2 + Im(P)^2 = 1$ が各サイ

トで成り立つべきである。DDPM は Re と Im を独立に生成するため、この拘束は明示的には課されない。

図 1（右）に示すように、全 β で $|Re^2 + Im^2 - 1| \approx 0.003$ であり、閾値 0.1 に対して桁違いに小さい。モデルが U(1) の単位円拘束をデータから暗黙的に学習したと言える。

## 5.4 可視化

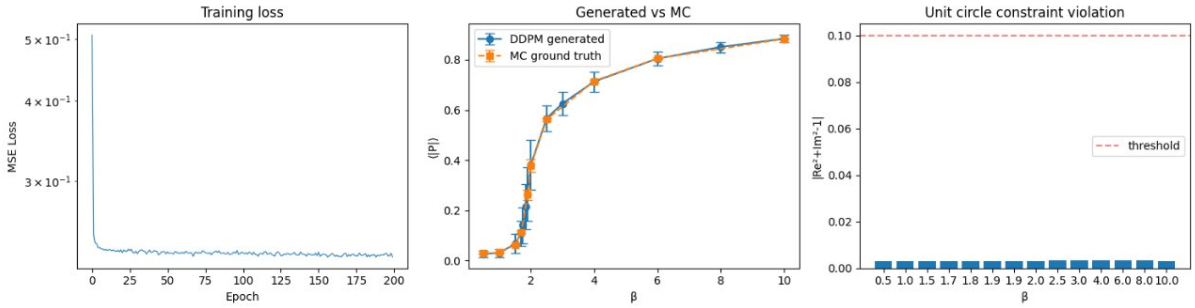


*図 1: 左: MSE loss の学習曲線。中央: DDPM 生成の ⟨|P|⟩（青）と MC ground truth (橙) の比較。右: 各 β における unit circle 拘束からの偏差。赤破線は閾値 0.1。*

# 6. 議論

## 6.1 何が言えるか

本実験の結果から、「β 条件付き DDPM は、⟨ |P|⟩ レベルで格子ゲージ理論の相構造を再現できる」と言える。根拠は以下の通り。

第一に、訓練 β 全点で MC との偏差が Δ ≤ 0.006 であること。特に相転移領域での急峻な立ち上がりを追従していることは、条件付けが機能している強い証拠である。もし β 条件が無視されていれば、この領域の ⟨ |P|⟩ は平滑化されるはずだからである。

第二に、held-out β の補間結果が隣接する訓練点の間に滑らかに収まっていること。これは β embedding が連続的な物理量として機能していることを示唆する。

第三に、unit circle 拘束が明示的に課されていないにもかかわらず ~0.003 の精度で自発的に守られていること。モデルが U(1) 群の構造をデータ駆動で学習したことを意味する。

## 6.2 何がまだ言えないか

一方、今回の検証は一次モーメント（平均 ⟨ |P|⟩ ）に限定されている。相構造を「完全に学べた」と主張するには、以下の追加検証が必要である。

(a) 分布形状の検証: ⟨ |P|⟩ のヒストグラムが MC と一致するか。特に相転移近傍では double-peak 構造（対称性の自発的破れに由来）が現れるかが鋭い検証になる。

(b) 高次統計量: Polyakov loop の空間相関関数 ⟨ P(0)P*(r)⟩ が正しい減衰挙動を示すか。

(c) トポロジカル指標: persistent homology などによるトポロジカル特性の比較。これは Phase 2b 以降の課題となる。

(d) held-out β の「自然な補間」が、β embedding の連続性から半ば自動的に出る振る舞いなのか、分布の内部構造まで正しく学んだ結果なのかの区別。これは ⟨ |P|⟩ だけでは判定できない。

## 6.3 技術的注記

本実験は当初 Google Colab (T4 GPU) で実施予定であったが、無料枠の GPU 使用時間超過により Kaggle Notebook (T4) に移行した。コードの修正はファイルパスの変更（/content/ → /kaggle/working/）と、torch.cuda.get_device_properties の属性名修正（total_mem → total_memory）のみであり、モデルや学習ロジックの変更はない。

# 7. 結論と次のステップ

Phase 2a の目標であった「β 条件付き DDPM が Polyakov loop の一次統計量を再現できるか」に対して、肯定的な結果を得た。訓練 β では Δ ≤ 0.006 の精度で MC 参照値と一致し、held-out β では滑らかな補間が確認された。unit circle 拘束も暗黙的に学習された。

Phase 2b 以降では、⟨ |P|⟩ のヒストグラム比較、空間相関関数の検証、およびトポロジカル指標の導入により、生成品質のより厳密な評価を行う予定である。

# 参考文献

[1] Ho, J., Jain, A., & Abbeel, P. (2020). Denoising Diffusion Probabilistic Models. NeurIPS 2020.

[2] Nichol, A. Q. & Dhariwal, P. (2021). Improved Denoising Diffusion Probabilistic Models. ICML 2021.
[3] Dhariwal, P. & Nichol, A. Q. (2021). Diffusion Models Beat GANs on Image Synthesis. NeurIPS 2021.
[4] Boyda, D. et al. (2021). Sampling using SU(N) gauge equivariant flows. Phys. Rev. D 103, 074504.